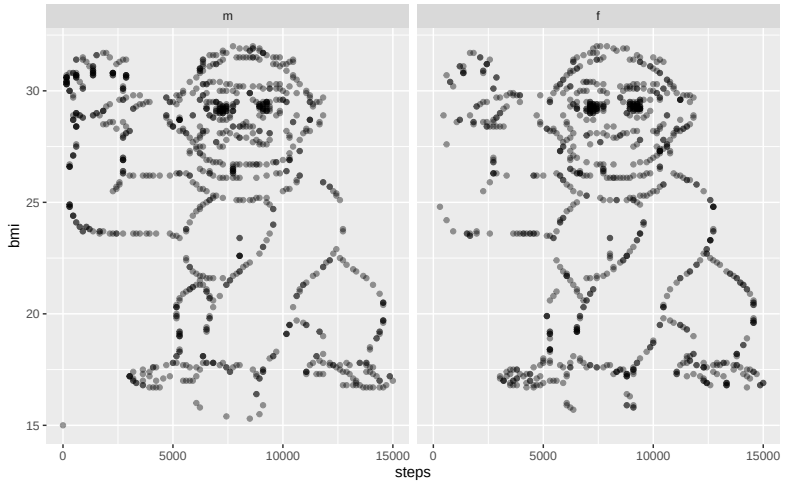
Auswertung eines Datensatzes

Arbeitsblatt 2

Principles of Data Visualization -- Herbstsemester 2026



Autor: Elio Schmid,
FH Graubünden, MSc Data Visualization

Dozentin: PD Dr. rer. nat. Helena Jambor

Ort, Datum: Bern, 06.10.2026

1 Datensatz

1.1 Was beschreibt der Datensatz?

Es werden zwei Datensätze untersucht. Darin werden die Anzahl Schritte pro Tag und der dazugehörige BMI einer Person aufgeführt. Einmal werden die Daten für Jungen dargestellt und einmal für Mädchen. Insgesamt handelt es sich um 1786 Beobachtungen. Davon entfallen 921 auf Jungen und 865 auf Mädchen. Bei der Anzahl Schritten bewegen sich die Beobachtungen zwischen 0/301 (Jungen/Mädchen) und 15'000 (Jungen & Mädchen). Der BMI bewegt sich zwischen 15/15.7 (Jungen/Mädchen) und 32 (Jungen & Mädchen).

1.2 Gibt es einen Unterschied zwischen den mittleren Schrittzahlen der Jungen und Mädchen?

Der Mittelwert der Mädchen und Jungen unterscheidet sich absolut. Mädchen gehen im Mittel 8014 Schritte und Jungen 6891, was einem Unterschied von 1123 entspricht.

Tabelle 1: Kennzahlen nach Gender der Variable "Anzahl Schritte".

Gender	n	Mittelwert	Standardabweichung	Median
m	921	6891	3674	7130
f	865	8014	3255	7894

Statistisch gesehen unterscheiden sich die Mittelwerte ebenso. Auf Basis der Annahme, dass die Daten einer Normalverteilung folgen, wurde ein Welch T-Test auf Mittelwertgleichheit durchgeführt. Die Hypothese wurde auf dem 5%-Signifikanzniveau verworfen.

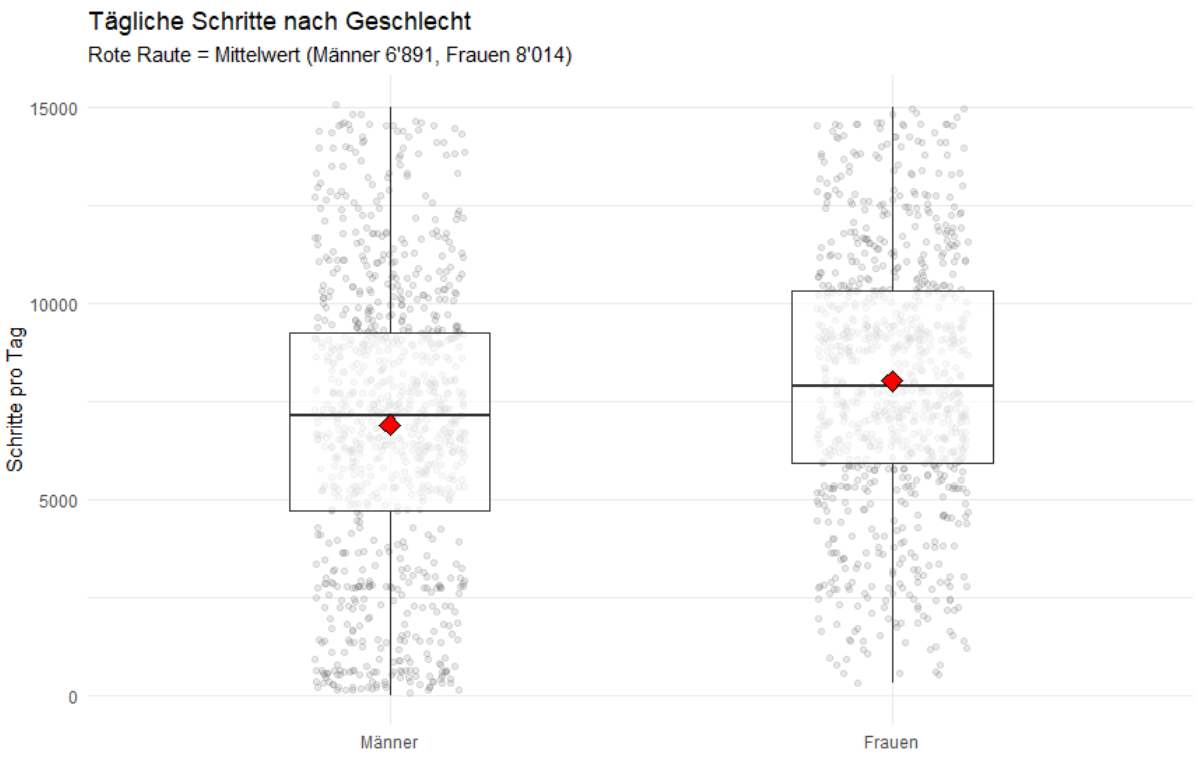


Abbildung 1: Boxplot je Gender mit Mittelwert

1.3 Gibt es eine positive Korrelation zwischen der Schrittzahl und dem BMI bei Jungen?

Eine positive Korrelation zwischen der Schrittzahl und dem BMI bei Jungen gibt es in dem Sinne nicht, als dass man sagen kann, dass bei höherer Schrittzahl der BMI zunimmt (statistisch würde dies einem positiven Zusammenhang entsprechen). Es ist eher das Gegenteil der Fall, dass die Daten negativ korrelieren, was in dem Sinne eine positive Aussage sein könnte. Nämlich je mehr Schritte desto niedriger der BMI. Wichtig zu erwähnen ist, dass diese Feststellung noch nicht einer Ursache-Wirkungs-Beziehung entspricht. Es wäre falsch zu behaupten, dass der BMI sinkt, je mehr Schritte ein Junge macht.

Wenn wir die Daten in einem Streudiagramm darstellen, sehen wir dass dadurch eine Figur entsteht. Somit ist der rechnerisch belegte Zusammenhang doch äusserst fraglich. Dies ist sowohl bei den Jungen als auch bei den Mädchen der Fall.

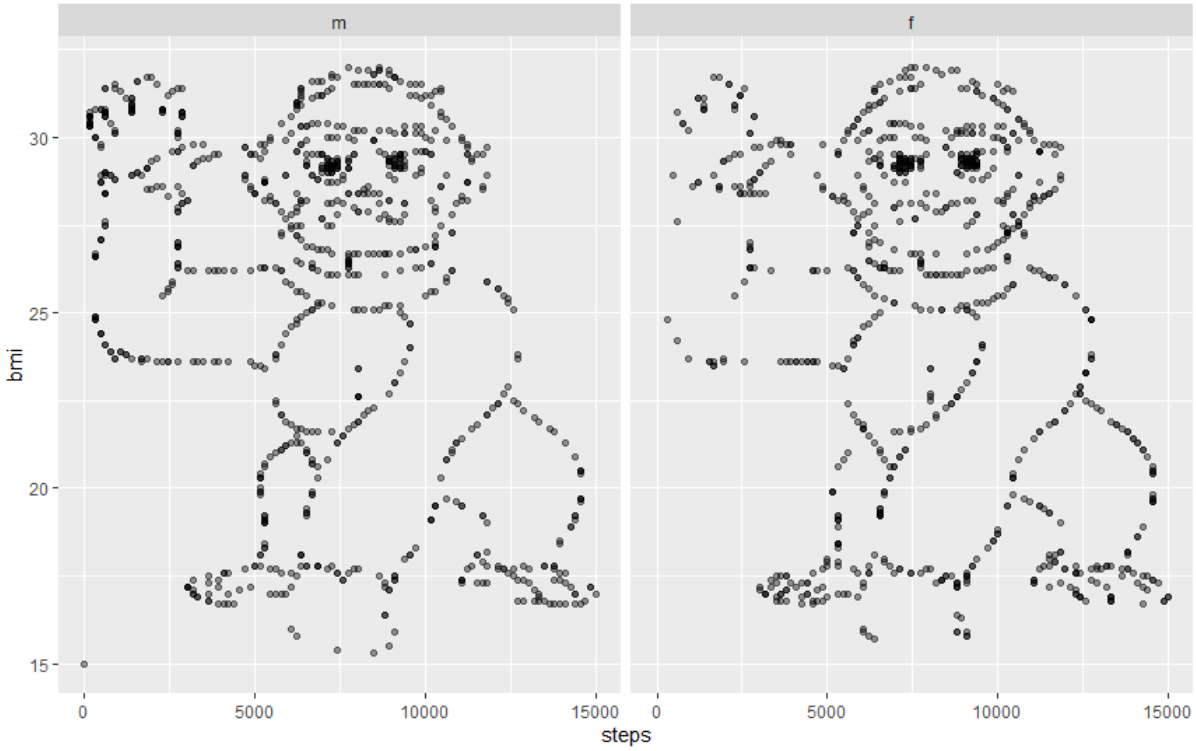


Abbildung 2: Streudiagramm je Gender

In der folgenden Abbildung wurde dem Streudiagramm die dazugehörige Regressionsgerade hinzugefügt. Die Punkte folgen keiner einfachen linearen Beziehung.

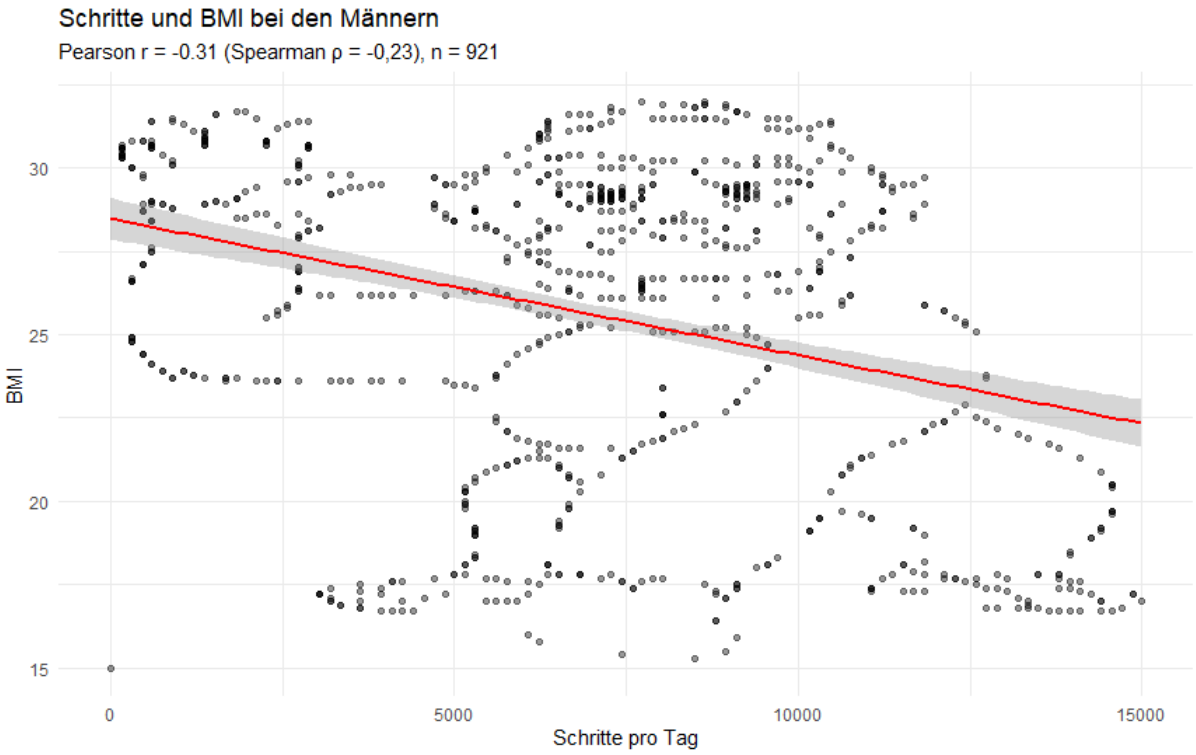


Abbildung 3: Streudiagramm je Gender mit Regressionsgerade

1.4 Welche weiteren Schlüsse können ihr bilden, oder Hypothesen aufstellen?

- Gibt es einen Unterschied zwischen den mittleren BMI der Mädchen und Jungen?
- Besteht auch bei den Mädchen einen negativen Zusammenhang zwischen Anzahl Schritte und BMI?
- Weisen die Jungen bei den Anzahl Schritten eine höhere Streuung auf als die Mädchen?
- Welche Personen Gruppe geht mehr pro Tag?

2 Iterationen

2.1 Beeswarm Chart

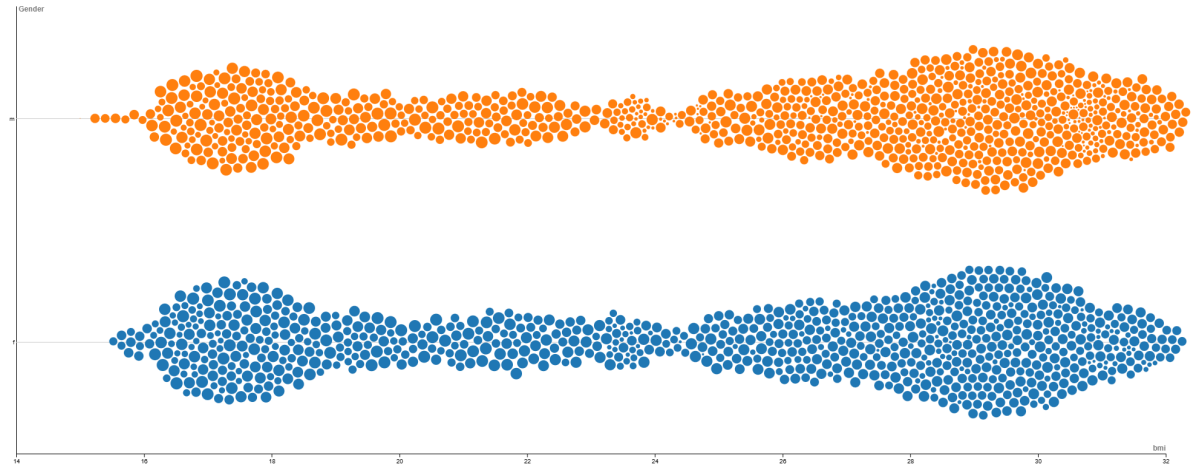


Abbildung 4: BMI je Gender. Die Kreisgrösse definiert die Anzahl Schritte pro Tag (Kodierung in der Fläche).

Dieser Chart ist insofern interessant, als dass sich relativ gut erkennen lässt, dass es auch Personen mit hohem BMI gibt, die täglich eine grosse Anzahl Schritte machen. Zeitgleich gibt es Personen, die eine niedrige Anzahl täglicher Schritte haben, die aber als Normalgewichtig eingestuft werden. Diese Visualisierung funktioniert meiner Meinung nach fast noch besser als interaktive Darstellung.

2.2 Violine Plot

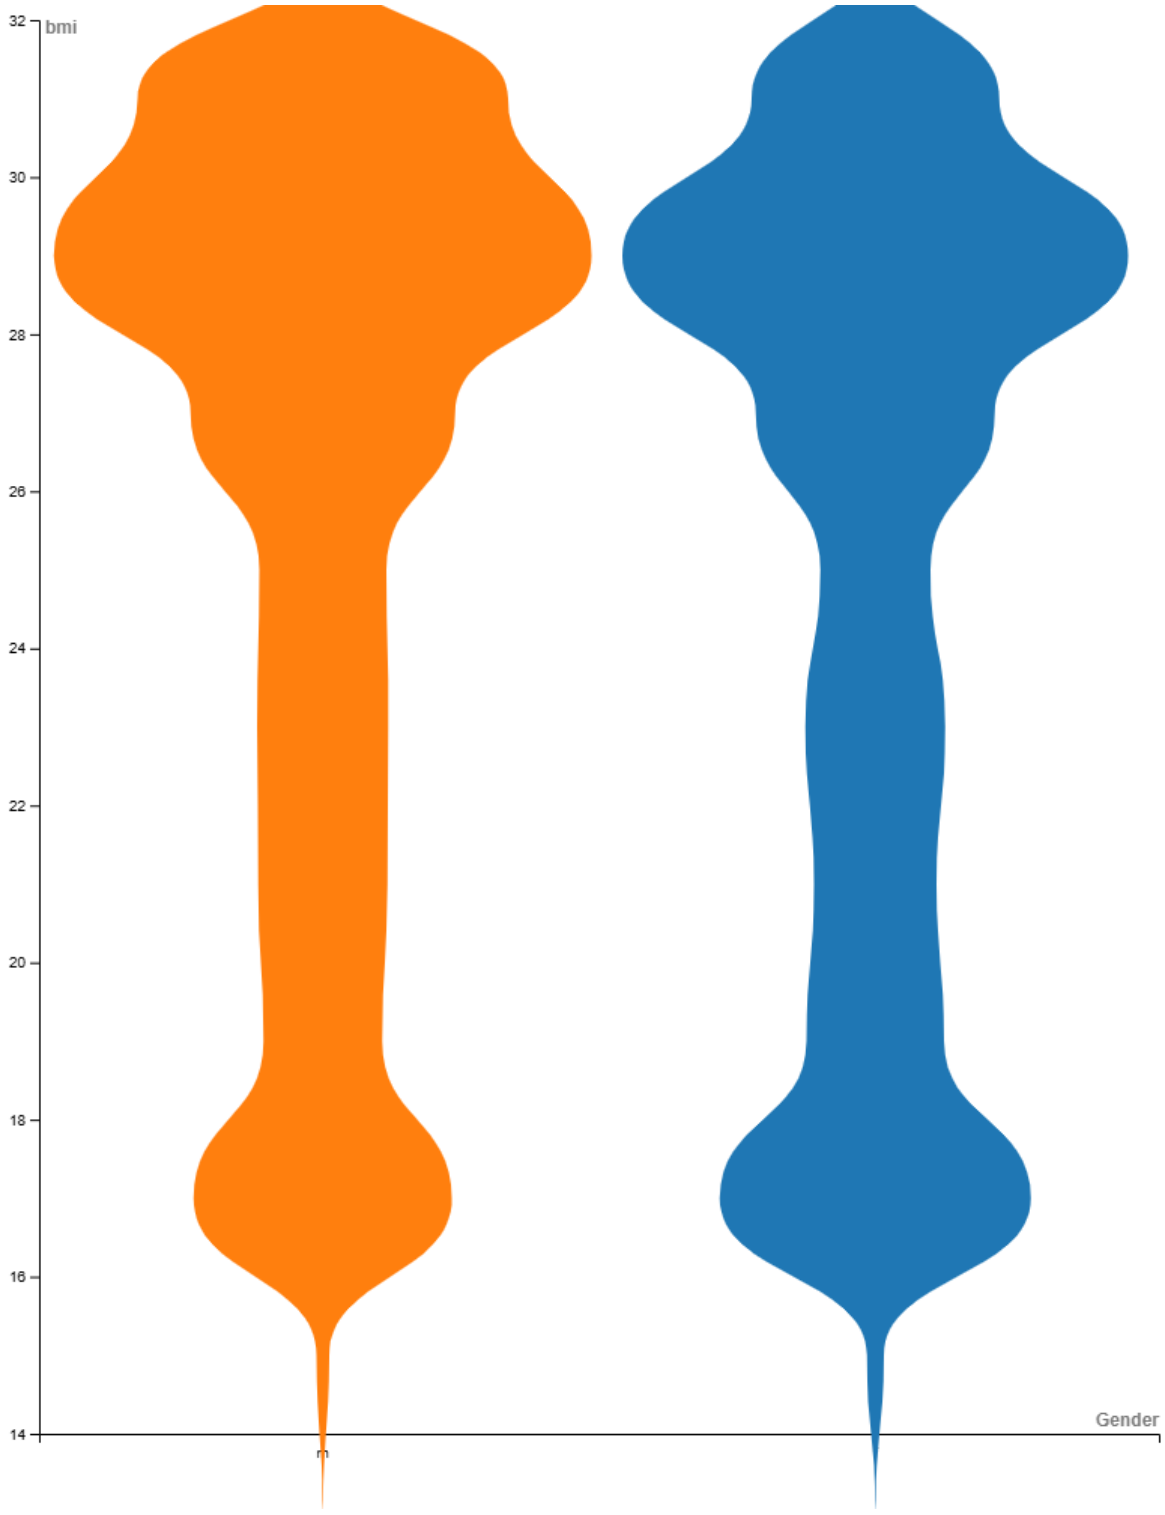


Abbildung 5: Violinplot des BMI je Gender

Bei diesem Chart hatte ich in der Erstellung Mühe. Die Visualisierung sagt aus, welche BMI's wie häufig vorkommen. Jedoch zieht es mir den Chart unter die X-Achse obschon keine Werte unter 14 bestehen. Somit stufe ich diesen Chart als wenig hilfreich ein.

2.3 Contour Plot

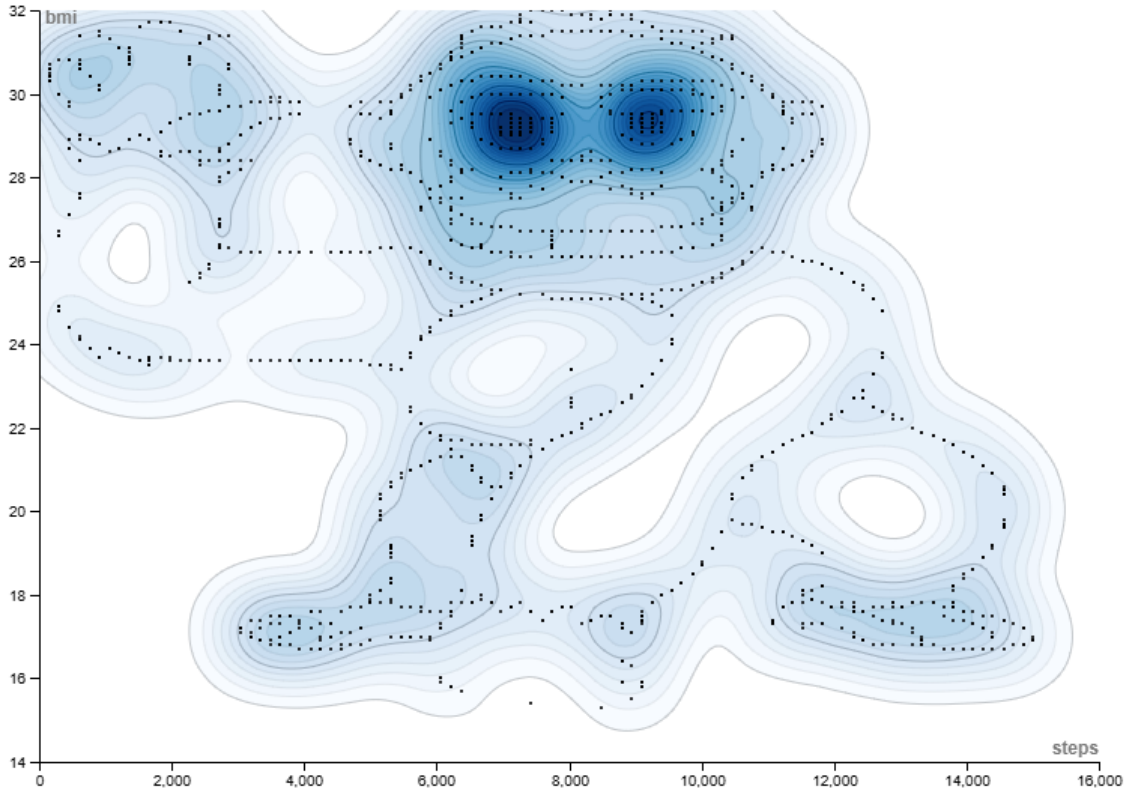


Abbildung 6: Contour Plot zu Schritten und BMI

Zusätzliche Darstellung zum Streudiagramm, wo mit der Farbgebung eine Art Heatmap erstellt wird. Je dunkler desto mehr Datenpunkte sind in einem Bereich vorhanden.

2.4 Line Chart

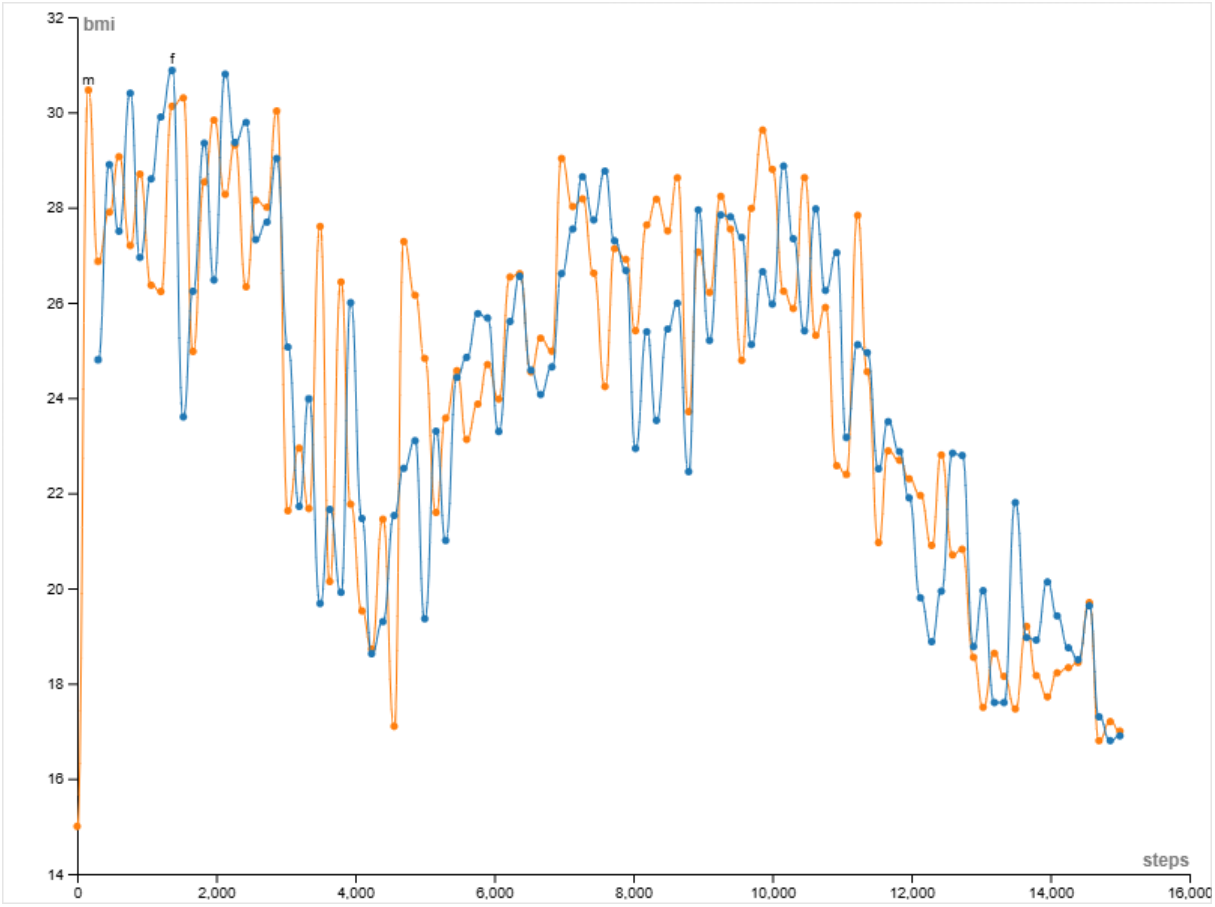


Abbildung 7: Durchschnittlicher BMI nach Anzahl Schritte, je Gender

In dieser Visualisierung wird der durchschnittliche BMI bei einer gewissen Anzahl Schritte als Linien Chart dargestellt. Die Daten der Jungen sind in Orange und die Daten der Mädchen in Blau dargestellt. Die Visualisierung liest sich wie folgt. Der durchschnittliche BMI der Jungen, die 0 tägliche Schritte absolvierten ist 15 (genau 1 Beobachtung). Aus dieser Grafik können wir lesen, dass der BMI je nach Anzahl Schritte von eher Tief zu eher Hoch schwankt.

3 Abschluss Teil 1

Alles in Allem finde ich, dass für die Darstellung dieser Daten das Streudiagramm am aussagekräftigsten ist. Ich habe die Auswahl verschiedener Visualisierungen als anspruchsvoll wahrgenommen und habe gemerkt, dass ich mich mit diesen Tools noch stärker auseinandersetzen muss, damit ich gelungene Visualisierungen umsetzen kann.

4 Aufgabe 2 Teil 2

4.1 Euere eigenen Analysen und Daten zu Gesundheit und Nachhaltigkeit

Anfang Oktober habe ich einen Artikel von SRF über den Gletscherschwund in der Schweiz gelesen. Der Artikel ist hier verlinkt. Darin wird auf Daten von Glamos - Glacier Monitoring in Switzerland verwiesen. Das Thema interessiert mich insofern, als dass ich relativ viel in den Bergen unterwegs bin. Auf der Website von Glamos finden wir Daten zu Bestand, Längenänderung, Massenbilanz, Volumenänderung sowie Szenarien. Die Daten unterscheiden sich in Stichtagsmessungen und Zeitreihen. Es werden Flächen-, Ausdehnungs- und Geodaten erfasst. In meiner Analyse möchte ich mich auf die Volumenänderung konzentrieren. Ich kann mir aber vorstellen auch Bestandesdaten einfliessen zu lassen oder Längenänderungen. Dies werde ich im Zuge der Auswertung wohl feststellen. Der Datensatz, den ich analysieren möchte, lässt sich hier einsehen.

5 Aufgabe 3

5.1 Daten einlesen

Die Datei enthält 6 Zeilen Metadaten, die Kopfzeile (Zeile 7) und eine Einheitenzeile (Zeile 8). Die Daten beginnen erst in Zeile 9.

```
Rows: 19,017
Columns: 16
$ `SGI-ID`      <chr> "A10g-02", "A10g-02", "A10g-02", "A10g-02", "A10g-02", "~
$ source_start  <chr> "dhm25-l1", "dhm25-l1", "dhm25-l1", "dhm25-l1", "sa3d-20~
$ source_end    <chr> "sa3d-2018", "ss3d-r2024", "sa3d-2022", "is-stand", "ss3~
$ date_start    <chr> "19919999", "19919999", "19919999", "19919999", "2014999~
$ date_end      <chr> "20149999", "20200821", "20219999", "20220715", "2020082~
$ A_start       <dbl> 0.5900, 0.5900, 0.5900, 0.5900, 0.3075, 0.3075, 0.0392, ~
$ outline_start <dbl> 1973, 1973, 1973, 1973, 2014, 2014, 1973, 1973, 1973, 19~
$ A_end         <dbl> 0.3075, 0.2073, 0.2073, 0.2073, 0.2073, 0.2073, 0.0150, ~
$ outline_end   <dbl> 2014, 2022, 2022, 2022, 2022, 2022, 2014, 2014, 2014, 20~
$ dV            <dbl> -0.010135, -0.012218, -0.010129, -0.013612, -0.002082, -~
$ dh_mean       <dbl> -17.140, -20.691, -17.153, -23.052, -6.763, -10.013, -6.~
$ Bgeod         <dbl> -0.835, -0.898, -0.720, -0.936, -1.146, -1.272, -0.287, ~
$ sigma         <dbl> 0.152, 0.167, 0.123, 0.167, 0.201, 0.324, 0.276, 0.249, ~
$ covered       <dbl> 100.0, 100.0, 100.0, 100.0, 100.0, 100.0, 100.0, 100.0, ~
$ rho_dv        <dbl> 850, 850, 850, 850, 850, 850, 850, 850, 850, 850, 850, 8~
```

```
$ Name          <chr> "Seegletscher", "Seegletscher", "Seegletscher", "Seeglet~
```

5.2 Bereinigung

5.3 Datenqualität

```
# A tibble: 3 x 2
  variable        n_na
  <chr>          <int>
1 area_start_km2    73
2 area_end_km2      11
3 groessenklasse    73
```

```
# A tibble: 1 x 2
  start_geschaetzt ende_geschaetzt
             <dbl>           <dbl>
1            0.649           0.167
```

```
# A tibble: 15 x 2
   name                     n
   <chr>                <int>
 1 Alphubel                 2
 2 Bas Glacier d'Arolla     2
 3 Breithorn                2
 4 Geisshorn                2
 5 Glacier de Moiry         2
 6 Grand Cornier            2
 7 Kleines Aletschhorn      2
 8 Olmenhorn                2
 9 Piz Pischa               2
10 Piz Vadret               2
11 Ritterpass               2
12 Sattelhorn               3
13 Schaligletscher E        2
14 Stockfirn W              2
15 Tournelon Blanc E        2
```

5.4 Basiskennzahlen

Kennzahl	Wert
Anzahl Messperioden (Zeilen)	19’017
Anzahl Gletscher	1’438
Messperioden pro Gletscher (Median)	16
Zeitraum	1850 bis 2024
Massenbilanz [m w.e. aź] (Median)	-0.49
Anteil Gletscher mit negativer Massenbilanz	99.3%

```
area_start_km2        dv_km3              dh_mean_m        bgeod_mwe_a
Min.   : 0.0029   Min.   :-6.1451090   Min.   :-83.713   Min.   :-2.1130
1st Qu.: 0.0717   1st Qu.:-0.0106270   1st Qu.:-22.355   1st Qu.:-0.6857
Median : 0.1908   Median :-0.0029850   Median :-16.447   Median :-0.4920
Mean   : 0.9501   Mean   :-0.0333257   Mean   :-16.951   Mean   :-0.5286
3rd Qu.: 0.5208   3rd Qu.:-0.0007988   3rd Qu.: -9.892   3rd Qu.:-0.3272
Max.   :92.1042   Max.   : 0.0003360   Max.   :  3.804   Max.   : 0.1490
NAs    :16
  sigma_mwe      periode_jahre
Min.   :0.0450   Min.   :  2.987
1st Qu.:0.1490   1st Qu.: 36.030
Median :0.2180   Median : 40.060
Mean   :0.2623   Mean   : 41.833
3rd Qu.:0.3360   3rd Qu.: 50.954
Max.   :0.9940   Max.   :171.951
```

5.5 Deskriptive Statistik nach Gruppen

Tabelle 2: Massenbilanz nach Einzugsgebiet (längste Periode je Gletscher)

einzugsgebiet	n	median	mittel	sd	dv_summe_km3
A	659	-0.46	-0.50	0.28	-14.39
B	585	-0.49	-0.52	0.29	-28.91
C	87	-0.52	-0.58	0.27	-1.64
E	107	-0.73	-0.75	0.25	-2.98

Tabelle 3: Massenbilanz nach Flächenklasse (längste Periode je Gletscher)

groessenklasse	n	median	mittel	sd
<0.1	455	-0.34	-0.40	0.30
0.1-0.5	598	-0.51	-0.54	0.25
0.5-2	254	-0.64	-0.66	0.25
2-10	92	-0.61	-0.66	0.29
>10	23	-0.44	-0.51	0.24

5.6 Visualisierungen

5.6.1 Verteilung der Massenbilanz

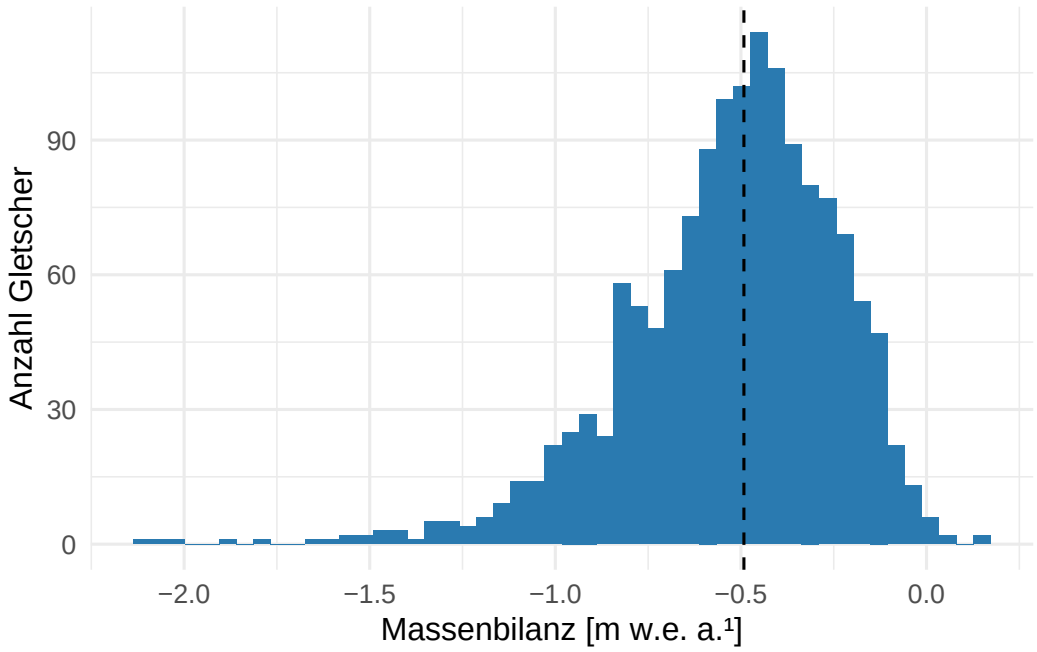


Abbildung 8: Verteilung der geodätischen Massenbilanz (längste Periode je Gletscher)

5.6.2 Gletschergrösse und Massenbilanz

5.6.3 Massenbilanz nach Gruppen

5.6.4 Zeitverlauf

Nur Perioden von 4 bis 15 Jahren, damit die Werte vergleichbar sind.

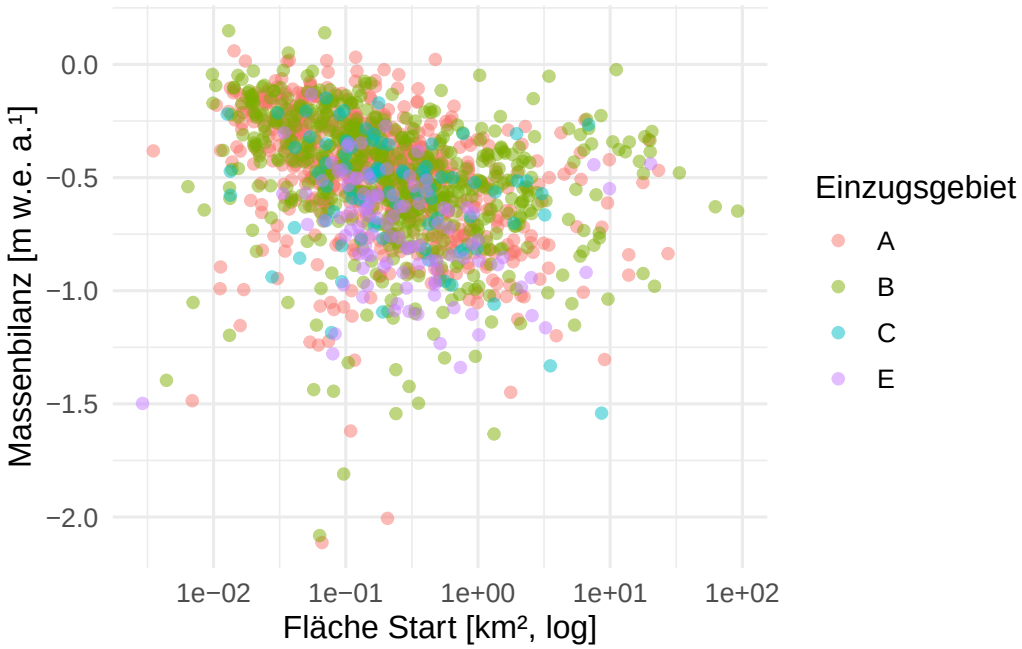


Abbildung 9: Gletscherfläche (Start) und Massenbilanz

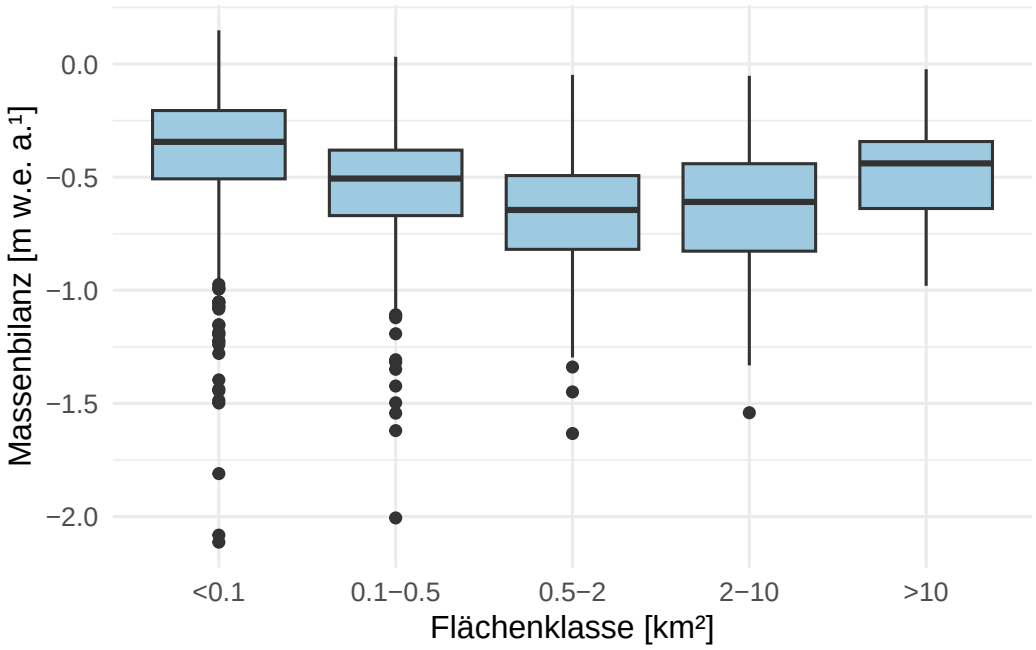


Abbildung 10: Massenbilanz nach Grössenklasse

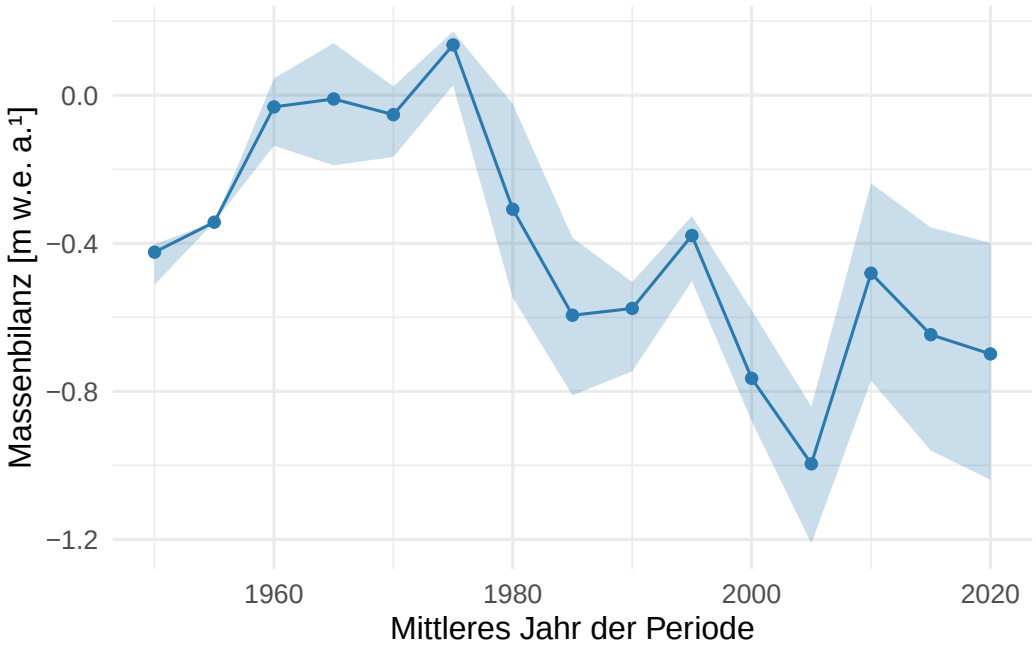


Abbildung 11: Massenbilanz im Zeitverlauf (Median und Quartile, 5-Jahres-Klassen)

5.6.5 Grösste Volumenverluste

5.7 Einfache Zusammenhangsprüfung

```
    Spearman's rank correlation rho

data:  gl_lang$area_start_km2 and gl_lang$bgeod_mwe_a
S = 684272339, p-value < 2.2e-16
alternative hypothesis: true rho is not equal to 0
sample estimates:
      rho
-0.427847

    Kruskal-Wallis rank sum test

data:  bgeod_mwe_a by einzugsgebiet
Kruskal-Wallis chi-squared = 87.088, df = 3, p-value < 2.2e-16
```

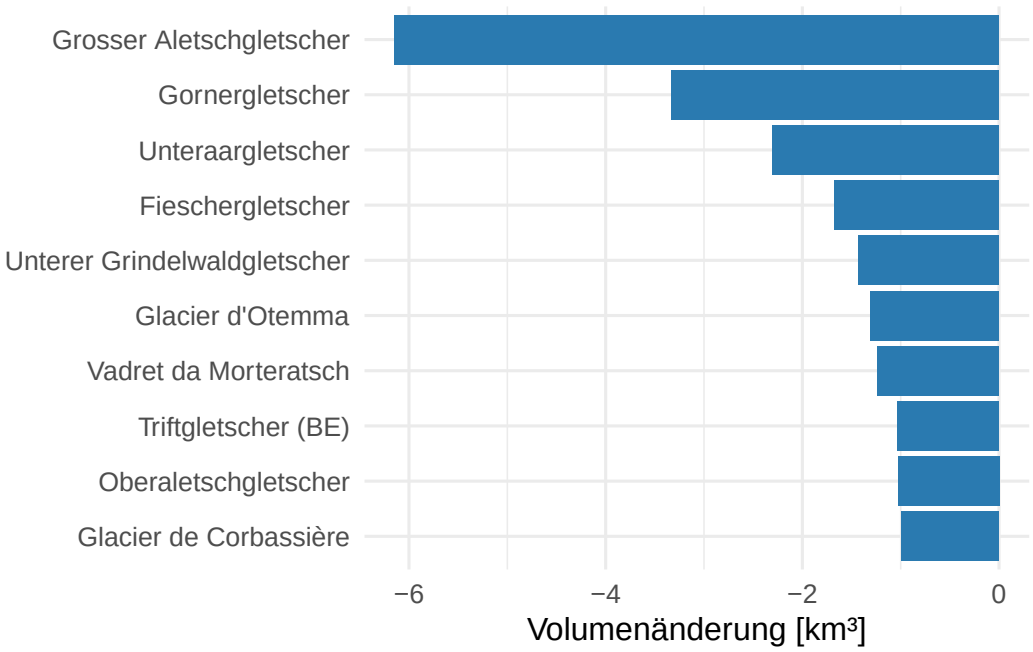


Abbildung 12: Die 10 Gletscher mit dem grössten Volumenverlust (längste Periode)